ISSN 2383-6318(Print) / ISSN 2383-6326(Online)
KIISE Transactions on Computing Practices, Vol. 26, No. 7, pp. 312-321, 2020. 7
https://doi.org/10.5626/KTCP.2020.26.7.312

다측면 기계학습을 사용한 스마트 이동 객체의 위치 보정 기법

(A Location Compensation Method for Smart Mobile Objects using Multilateral Machine Learning)

권 용 훈 † 정 인 범 ††
(Yonghun Kwon) (Inbum Jung)

요 약 사물인터넷 환경에서 위치 기반 서비스를 위한 기술 중에서 블루투스 비콘은 활발하게 연구되고 있는 기술이다. 비콘에서 발산되는 신호 중 RSSI 값을 이용하여 실내에서 이동 중인 스마트 객체와 사물 간의 거리측정을 유도할 수 있다. 그러나 RSSI는 신호의 반사와 회절과 같은 현상에 의해 영향을 받아 정확도가 높지 않은 문제점을 가지고 있다. 본 논문에서는 다측면 기계학습 알고리즘들을 사용하여 RSSI를 사용한 거리측정의 정확도를 높이는 연구를 진행하였다. 저주파 통과 필터와 파라미터 학습 그리고 역전파 학습을 순차적으로 진행하여 거리를 측정하였다. 제안된 다측면 기계학습 방식의 성능 평가를 위해 실험의 각 단계에서 유도된 거리와 실제 거리 간의 오차를 바탕으로 정확도를 평가하였다. 실험 결과 제안된 거리측정 방식은 제한된 거리 범위 내에서 실측값에 근접한 거리 값을 유도함을 보이므로, 사물인터넷 망에서 위치 인식 서비스 응용프로그램에 기여할 수 있음을 보였다.

키워드: 다측면 학습, 저주파 통과 필터, 파라미터 학습, 신경망, 스마트 모바일 객체

Abstract Bluetooth technology has been widely used for location awareness services in IoT network environments. RSSI emitted from a beacon can be utilized to measure the distance between smart mobile objects that are moving indoors. However, reflection and diffraction phenomena that affect RSSI often result in inaccurate distance measurements. In this paper, multilateral machine learning algorithms are applied to enhance the accuracy of distance measurements based on RSSI. First, a low-pass filter is used to correct estimates that overshoot among the measured RSSI data. Second, a parameter control leaning method is used and the distance translation equation is supplied with corrected RSSI data. Although this equation can predict distance from the strength of the RSSI signal it can generate errors when it comes to the range of the distances estimated. To reduce these range of distance errors, a back propagation neural network algorithm is applied. For performance evaluation, we compare the actual distance values with the estimated distance values that come from each stage during the multilateral machine learning. The estimated values were found to be close to the actual distances within the limited scope of distances tested, as such, we believe this technology can contribute to location awareness service applications in IoT networks.

Keywords: multilateral learning, low pass filter, parameter learning, neural network, smart mobile object

· 본 연구 성과는 정부(과학기술정보통신부)의 재원으로 한국연구재단의 지원을 받아 수행된 연구임(No. 2019R1F1A1058835)

† 학생회원 : 강원대학교 컴퓨터정보통신공학과 학생
russell1113@kangwon.ac.kr
†† 종신회원 : 강원대학교 컴퓨터정보통신공학과 교수
(Kangwon Nat'l Univ.)
ibjung@kangwon.ac.kr
(Corresponding author임)

논문접수 : 2020년 2월 3일
(Received 3 February 2020)
논문수정 : 2020년 5월 27일
(Revised 27 May 2020)
심사완료 : 2020년 5월 28일
(Accepted 28 May 2020)

Copyright©2020 한국정보과학회 : 개인 목적이나 교육 목적인 경우, 이 저작물의 전체 또는 일부에 대한 복사본 혹은 디지털 사본의 제작을 허가합니다. 이 때, 사본은 상업적 수단으로 사용할 수 없으며 첫 페이지에 본 문구와 출처를 반드시 명시해야 합니다. 이 외의 목적으로 복제, 배포, 출판, 전송 등 모든 유형의 사용행위를 하는 경우에 대하여는 사전에 허가를 얻고 비용을 지불해야 합니다.

정보과학회 컴퓨팅의 실제 논문지 제26권 제7호(2020. 7)

1. 서 론

사물인터넷(IoT: Internet of Things)은 지능화된 사물들이 상호 호환 가능한 정보와 통신 기술을 통해 지능형 서비스를 제공하는 인프라다[1]. 사물인터넷이 발전하면서 활발히 연구되는 분야는 위치를 기반으로 한 서비스 분야이다. 특히 무인자동차, 드론 등 자율 이동 객체를 바탕으로 한 연구들이 성공적으로 많은 성과를 내면서 진행되고 있다. 자율 이동객체는 사람의 도움 없이 외부의 환경을 인식하고 상황을 판단하여 동작하는 이동객체를 의미한다. 자율 이동객체는 1차 산업인 농업에서부터 운송, 인간의 안전과 복지를 위한 공공서비스 등 다양한 분야에 적용할 수 있고 미래에는 더 많은 분야에 핵심기술로 떠오르고 있다. 스마트 이동객체는 자율 이동객체의 일종으로 실내에서 스스로 위치를 판단하고 정해진 위치까지 이동하여 자신의 임무를 수행하는 이동객체이다. 자율 이동객체의 핵심기술은 크게 5가지로 구분할 수 있다. 외부의 환경에서 데이터를 얻어 인식하는 탐지 및 인식 기술, 스스로 움직이거나 다른 물체를 이동시키는 동력원 및 이동 기술, 스스로 상황을 판단하고 결정하는 자율지능 기술, 사용자 혹은 다른 이동체와 통신할 수 있는 통신기술 그리고 위의 4가지 기술을 통합할 수 있는 시스템 통합 기술이다[2].

블루투스 4.0(BLE, Bluetooth Low Energy)은 이전 세대에 비해서 최대 90%까지 전력소모를 절감한 저전력 통신 기술이다. 덕분에 배터리 용량을 줄여 디바이스를 소형화할 수 있게 되었고, 비콘(Beacon)이라는 개념이 등장하였다. 비콘은 고정된 위치에서 자신의 고유한 신호를 발생시키는 장치다. 비콘은 표준기술을 기반으로 하여 호환성이 우수하고, 값이 저렴하다는 특징이 있다. 이러한 특징 때문에 IoT 인프라 구축이 용이하다. 이를 바탕으로 근래에 실내위치기반서비스(Indoor Location Based Service)가 활발하게 연구되고 있다. 사물의 위치인식을 위해서는 비콘과 사물 간의 거리측정이 우선되어야 한다. 거리측정은 RSSI(Received Signal Strength Indication)를 기반으로 계산하는 방법이 있다. 그러나 RSSI는 주변의 환경에 의해 값이 일정하지 않아 이 방식으로는 높은 정확도를 기대하기 어렵다[3,4].

본 논문에서는 스마트 이동 객체의 정확한 거리측정을 위하여 다측면 기계학습을 이용한 위치 보정 기법을 제안한다. 다측면 기계학습은 저주파 통과 필터, 파라미터 학습 그리고 역전파 학습 순으로 진행된다. 우선 비콘 신호를 감지하는 비콘 스캐너를 이용하여 RSSI 초기 데이터를 측정한다. 측정된 값에서 변동 폭이 큰 RSSI 데이터를 보정하기 위하여 저주파 통과 필터를 적용한다. 다음으로 보정된 RSSI 값들을 학습데이터로 사용하여 파라미터 학습을 진행함으로써 실제 거리를 RSSI로 표현할 수 있는 최적의 수식을 획득한다. 마지막으로 파라미터 학습을 사용해서 얻은 수식으로 계산한 1차 추정 거리와 실제 거리간의 오차를 줄이기 위해 역전파 학습을 진행한다. 적용된 다측면 기계학습들을 통하여 스마트 이동객체의 동작 위치에 대한 예측 오차를 줄일 수 있다. 제시된 다측면 기계학습의 성능을 평가하기 위하여, 스마트 이동객체를 기반으로 실험 환경을 구축하였다. 제안된 다측면 기계학습 방식의 성능 평가를 위해 실험의 각 단계에서 유도된 거리와 실제 거리 간의 오차를 바탕으로 정확도를 평가하였다. 실험 결과 제안된 거리측정 방식은 제한된 거리 범위 내에서 실측값에 근접한 거리 값을 추정하는 것을 보임으로서, 사물인터넷 환경에서 위치 인식 서비스 응용프로그램에 기여할 수 있음을 보였다.

본 논문의 구성은 다음과 같다. 2장에서는 기존에 실내위치측위와 RSSI에 대한 개념과 기계학습에 대한 내용을 설명한다. 3장에서는 본 논문에서 제시하는 다측면 기계학습을 이용한 스마트 이동 객체의 위치 보정 기법을 기술한다. 4장에서는 시스템 구현과 실험 환경에 대해서 기술한다. 5장에서는 실험 결과를 바탕으로 성능평가 내용을 정리하며, 6장에서는 본 논문에서 서술한 내용을 결론으로 정리한다.

2. 관련연구

2.1 스마트 이동객체를 위한 실내 위치 측위

탐지 및 인식 기술 분야에서 무인자동차와 같이 실외에서 이동하는 객체들은 GPS(Global Positioning System)를 이용하여 정확한 위치 인식이 가능하다. 하지만 GPS를 이용한 위치 측위는 실내에서는 신호 수신이 어려워 적용하기 어렵다는 문제점이 있다[2]. 실내 환경에서는 무선 통신을 이용한 위치 측위 방식이 있으며, 전통적으로 삼각측량을 사용하고 있다. 삼각측량은 삼각형의 기하학적인 특성을 이용하여 대상의 위치를 추정하는 방식이다. 삼각측량의 방식은 크게 여러 기준점으로부터 거리를 측정하여 물체의 위치를 추정하는 방식인 lateration과 여러 기준점에서 상대적인 각도를 계산하여 객체를 찾는 방식이 있다. 통상적으로 사용하는 전자의 방식에는 TOA(Time of Arrival), TDOA(Tine Different of Arrival) 등이 있다[4]. TOA는 송신지에서 수신지까지 신호가 도달한 시간을 이용하여 거리를 계산하는 방식이다. TDOA는 TOA와 유사하지만 위치를 알고 있는 수신지들의 수신 시간 차이를 이용하는 방식이다[5].

2.2 RSSI(Received Signal Strength Indication)

RSSI는 수신한 라디오 신호의 강도를 의미한다. 일반

적으로 0~-100dBm 사이의 값을 가지며, 거리가 가까울수록 커지고 멀어질수록 작아지는 특성을 가진다. 이러한 특성을 이용하여 RSSI 값으로 거리를 추정할 수 있다. RSSI의 값은 식 (1)로 계산할 수 있다.

$$RSSI = -(10n\log_{10}d + TxPower) \quad (1)$$

식 (1)에서 n은 주변 환경 요인에 의해 정의되는 상수이다. 통상적으로 2~4의 값을 갖는다. d는 수신기와 송신기 간 거리를 나타낸다. $TxPower$는 송신기에서 1m 떨어진 곳에서 측정되는 RSSI 신호의 값이다. 식 (1)을 바탕으로 거리 계산식을 식 (2)와 같이 유도할 수 있다. 본 논문에서 서술할 때 식 (2)로 거리를 계산하는 방식을 기존의 방식이라고 칭한다.

$$Distance(m) = 10^{\frac{TxPower - RSSI}{10n}} \quad (2)$$

그러나 RSSI는 전파 신호이기 때문에 자유 공간에 의한 손실이나 주변의 장애물에 의한 반사와 회절과 같은 현상에 영향을 받아 거리로 변환하는 과정에서 정확도 감소가 발생한다[3-6].

2.3 저주파 통과 필터(Low Pass Filter)

저주파 통과 필터는 저주파 대역의 신호는 통과시키고 고주파 대역의 신호는 제거하는 재귀식 필터이다. 일반적으로 저주파 신호에서 발생하는 고주파의 잡음을 제거하기 위해 사용된다. 이 같은 특성은 RSSI와 같이 변화폭이 큰 데이터의 보정에 적합하다. 저주파 통과 필터의 수식은 아래와 같다.

$$\bar{x}_k = a\bar{x}_{k-1} + (1-a)x_k \quad (3)$$

식 (1)에서 a는 $0<a<1$ 범위를 갖는 상수이며, x_k는 현재 측정값, $\bar{x}_{k-1}$는 이전의 추정값이다. 현재 추정값($\bar{x}_k$)은 x_k와 $\bar{x}_{k-1}$을 이용하여 값을 구하는데, 오래된 값일수록 적은 가중치를 부여하고 최근 값일수록 높은 가중치를 부여한다. 데이터 흐름에 따라 가중치를 다르게 부여하는 저주파 통과 필터는 모든 값에 동일한 가중치를 부여하는 이동 평균 필터(Moving Average Filter)의 한계점을 보완할 수 있다[7].

2.4 파라미터 학습

파라미터 학습은 수많은 데이터쌍(x, y)이 주어졌을 때, 이것을 쉽게 표현할 수 있는 수식을 구하는 방식이다. 수식은 일반적인 다항식에서 대수 함수까지 다양한 형태로 유도할 수 있다. 본 논문에서는 식 (4) 형태의 선형 방정식을 구하고자 한다.

$$y = a_0 + a_1 x \quad (4)$$

식 (4)에서 각각의 계수를 구하기 위해서는 선형 회귀의 일종인 최소제곱법(Least Squares Method)을 이용한다. 최소제곱법은 선형 분포를 이루는 데이터쌍과 식의 결과값의 오차가 최소가 되도록 계수(a_0, a_1)를 결정한다. a_0와 a_1를 결정하기 위해서는 오차(S)를 식 (5)의 형태로 정의한다.

$$S = \sum (y_i - a_0 - a_1 x_i)^2 \quad (5)$$

이후 식 (5)을 a_0와 a_1로 각각 편미분하여 a_0와 a_1의 값을 구한다[8].

2.5 역전파 신경망

역전파 신경망(Back Propagation Neural Network)은 계층형 신경망을 이용하여 학습 과정에서 중간층의 연결강도를 조정하는 알고리즘이다. 신경망의 구조는 Input layer, 다수의 Hidden layer 그리고 Output Layer로 이루어져 있다.

그림 1에서 최초 학습 데이터가 Input layer로 들어오면, 학습 데이터는 Input layer에서 Hidden layer로 전달된다. 그 후 Hidden layer를 거쳐 Output layer에서 최종 출력된다. 그 후 출력값과 정답을 비교하여 오차를 계산한다. 오차는 출력에서 입력으로 역으로 할당되면서 연결강도를 조정한다. 이 과정을 반복하면서 허용 오차범위에 도달하면 학습을 종료하게 된다. 학습을 통해 입력과 정답의 오차를 최소화하는 연결강도의 집합을 얻을 수 있다[9,10].

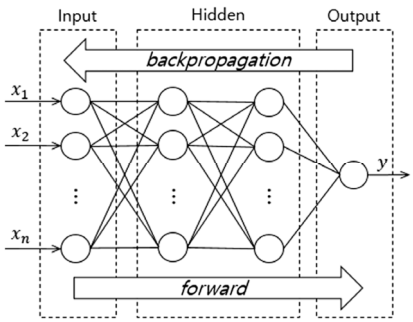

그림 1 역전파 신경망 구조도

Fig. 1 Structure of Back Propagation Neural Network

3. 스마트 이동 객체의 위치 보정

비콘은 고정된 위치에서 주기적으로 신호를 발산하는 장치다. 이를 바탕으로 다양한 위치기반서비스가 연구되고 있으며, 다른 사물과의 거리를 측정하기 위하여 RSSI 값을 이용한다. 하지만 RSSI는 데이터의 변동폭이 크기 때문에 기존의 단일 계산 모델로 거리를 계산할 경우 오차가 발생한다. 본 논문에서는 RSSI를 활용하여 비콘과 사물간의 거리를 측정하는 과정에서 다측면 기계학습을 적용하였다.

그림 2는 다측면 기계학습을 이용하여 스마트 이동 객체의 위치 보정을 위한 시스템 구조도이다. 다측면 기계학습은 크게 3가지의 모델을 사용한다. 첫 번째로

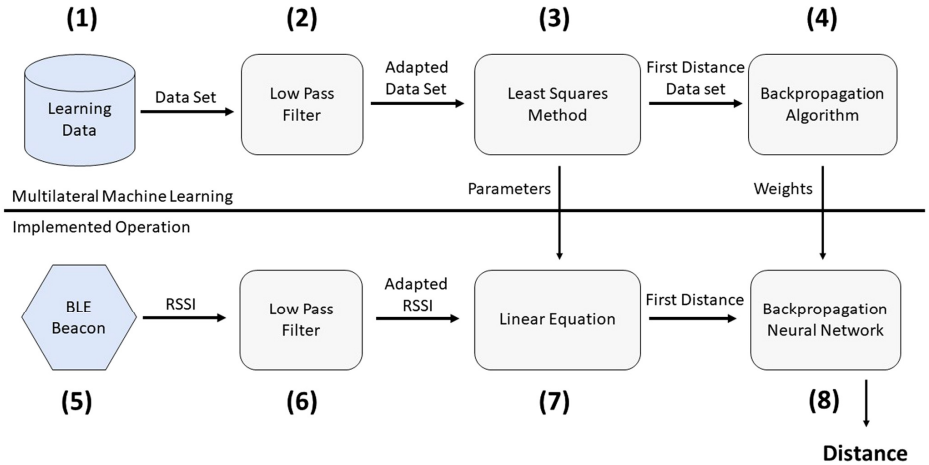

그림 2 스마트 이동 객체의 위치 보정 구조도
Fig. 2 Structure of Location Compensation for Smart Mobile Objects

RSSI의 변동폭을 줄이기 위해 저주파 통과 필터(2)를 적용한다. 두 번째로 필터 처리를 마친 데이터를 최소제곱법을 이용한 파라미터 학습(3)을 통해 수식을 얻고, 이를 이용하여 거리를 계산한다. 마지막으로 계산된 거리와 실제 거리간의 오차를 줄이기 위해 역전파 학습(4)을 진행한다. 학습이 끝난 후 파라미터 학습을 이용해 얻은 방정식의 계수는 시스템을 구현할 때 거리 계산식(7)으로 전달되고, 역전파 학습을 통해 얻은 노드의 연결강도는 역전파 신경망(8)로 전달되어 신경망을 구성한다. 시스템이 동작하는 과정은 비콘(5)에서 생성된 RSSI 데이터는 저주파 통과 필터(6)를 거쳐 보정되고, 보정된 RSSI는 거리 계산식(7)을 통해 1차 측정 거리를 계산하여 역전파 신경망(8)에 전달하게 된다. 신경망을 통과한 1차 측정 거리는 최종적으로 측정된 거리를 출력한다.

3.1 다측면 기계학습 단계

3.1.1 학습 데이터 생성

다측면 기계학습을 위해서는 학습데이터(1)를 구축해야한다. 학습 데이터는 비콘과 스마트 이동객체 간의 RSSI 데이터를 수집하여 생성한다. 비콘에서 일정 간격마다 측정 지점을 설정하여 스마트 이동 객체를 이동시킨 후 RSSI 데이터를 수집한다. 각각의 데이터는 측정한 지점의 거리와 함께 데이터 쌍을 만든다.

표 1 학습 데이터 셋의 일부
Table 1 Data used for Learning

Data Set	
RSSI Value	Distance
-40	100
-47	100
-41	100
-40	100
-46	100
…	…

표 1은 비콘에서 100cm만큼 떨어진 지점에서 측정한 학습 데이터 셋의 일부를 나타낸다. RSSI Value는 측정된 RSSI 값을 나타내고, -100~0dBm 사이의 정수값을 가진다. Distance는 비콘에서 떨어진 거리를 나타내며 RSSI 데이터를 측정한 지점이다.

3.1.2 저주파 통과 필터

저주파 통과 필터는 RSSI 데이터의 변동폭을 줄이기 위한 과정이다. 3.1.1에서 생성한 데이터 셋에서 거리 데이터는 동일하게 설정을 하고 RSSI 데이터만 저주파 통과 필터에 입력한다. 저주파 통과필터는 식 (3)과 같이 구성되어 있다. 여기서 a를 통해 필터의 강도를 조정할 수 있다. a가 작으면 새로운 값의 가중치가 증가하여 새로운 값의 변화에 예민해진다. 즉, 필터의 성능이 떨어지게 된다. a를 0.5보다 크게 설정할 경우 기존의 값의 가중치가 커지기 때문에 안정적인 데이터를 얻을 수 있게 된다. 본 논문에서는 a의 크기를 0.7로 설정하여 식 (6)과 같은 저주파 통과 필터 식을 적용한다. 식 (6)를 적용하면 RSSI 데이터의 변동을 70%정도 줄일 수 있는 효과가 있다.

$$\overline{x}_k = 0.7\,\overline{x}_{k-1} + 0.3\,x_k \tag{6}$$

표 2는 식 (5)를 이용하여 필터링한 결과를 보여주는 데이터 셋의 일부를 나타낸다. 각 항목은 표 1의 항목에 대응된다. 표 1에서 첫 번째 행과 두 번째 행의 데이터는 -7만큼 차이가 나지만, 필터를 적용한 표 2에서는 차이가 -2로 줄어들었다.

표 2 저주파 통과 필터를 통과한 데이터 셋의 일부
Table 2 Data Filtered by Low Pass Filter

Filtered Data Set	
RSSI Value	Distance
-40	100
-42	100
-41	100
-40	100
-41	100
…	…

3.1.3 파라미터 학습

파라미터 학습은 3.1.1에서 생성한 데이터를 저주파 통과 필터에 입력하여 얻은 보정된 데이터 셋으로 진행된다. 파라미터 학습은 2가지 단계로 이루어진다. 첫 번째는 최소제곱법을 이용하여 식 (4)와 같은 선형 방정식을 얻는 것이다. RSSI 데이터가 주어졌을 때 이것을 실제 거리와 근사하게 거리로 변환할 수 있는 수식을 통해 1차 추정 거리를 계산한다. 두 번째는 얻은 수식을 바탕으로 하여 역전파 학습을 위한 데이터 셋을 생성하는 것이다.

$$Distance(cm) = -10.179 * RSSI - 331.92 \quad (7)$$

첫 단계에서는 학습 데이터를 바탕으로 식 (7)과 같은 거리 계산식을 획득하였다. 식 (7)은 최소 제곱법을 통해 얻은 거리 계산식으로 RSSI 데이터를 입력하면 거리를 계산하여 출력한다. 본 시스템에서 식 (7)을 통해 계산된 거리를 '1차 측정 거리'라고 한다.

표 3은 1차 측정 거리 데이터 셋의 일부이다. First Estimated Distance는 표 2에 대응되는 RSSI 데이터를 식 (7)로 계산한 거리 값이다. 최소제곱법은 수많은 데이터 셋을 잘 표현할 수 있는 수식을 얻는 방식이다. 그러나 RSSI 데이터는 완전히 선형으로 분포하지 않는다. 이로 인해 표 3에서 볼 수 있듯이 1차 측정 거리와 실제거리 간에 오차가 발생한다.

표 3 1차 측정 거리 데이터 셋의 일부
Table 3 Data Estimated by Linear Equation

First Estimated Distance Data Set	
First Estimated Distance	Distance
75.218	100
95.575	100
85.397	100
75.218	100
85.397	100
…	…

3.1.4 역전파 학습

RSSI 데이터는 선형 분포의 형태를 이루고 있지 않기 때문에 파라미터 학습을 통해 얻은 수식으로 거리를 계산할 경우 오차가 발생하게 된다. 본 논문에서는 수식으로 계산된 거리와 실제 거리간의 오차를 줄이기 위해 역전파 학습 알고리즘을 적용하였다. 역전파 학습을 위해서는 신경망 모델을 구축해야 한다. 하지만 스마트이동객체와 같은 사물인터넷 환경에서는 제한된 자원으로 운용할 수 있어야 한다. 이러한 환경에서는 복잡한 신경망을 사용하기 어렵다. 최적의 성능을 위해 노드 수를 변화시키면서 평가율을 비교했다. 그 결과 Hidden layer에 4개의 노드를 구성한 모델이 92.1% 가장 높은 평가율을 나타냈다.

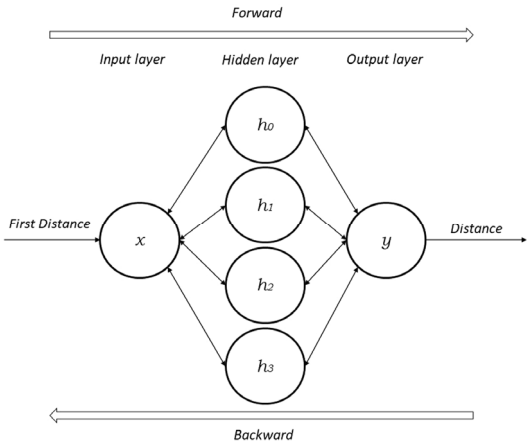

그림 3 거리 추정을 위한 역전파 신경망 구조도
Fig. 3 Back Propagation Neural Network for Distance Estimation

그림 3은 역전파 신경망 모델의 구조도이다. Input layer에는 수식으로 계산된 1차 측정 거리가 입력 되며 x에 대응된다. Hidden layer는 4개의 노드로 이루어져 있으며, Output에서는 신경망을 거쳐 y 노드에서 최종적으로 추정된 거리를 출력한다. Output layer에서 Hidden layer와 Output에는 활성 함수로 아래와 같은 Sigmoid 함수를 사용하였다.

$$f(x) = \frac{1}{1+e^{-x}} \quad (8)$$

식 (8)은 Sigmoid 함수를 나타낸다. Sigmoid 함수는 비선형이며, 0과 1사이의 값을 가지는 함수로 역전파 신경망에 적합한 함수이다.

3.2 다측면 학습 과정들의 상호 동작

그림 4는 스마트 이동 객체의 거리측정 과정을 나타낸 시퀀스 다이어그램이다. 특정 지점에 위치한 비콘(1)에서 비콘의 정보가 담긴 패킷을 주변의 블루투스 장비를 스캔 중인 스마트 이동 객체가 감지한다. 스마트 이동객체의 제어모듈(2)에서는 정보 패킷에서 RSSI 신호만 추출하여 저주파 통과 필터(3)로 전달한다. 저주파

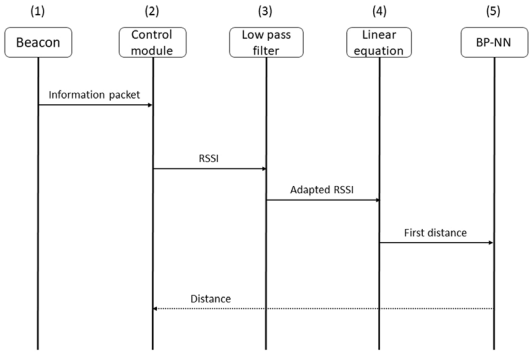

그림 4 다측면 학습과정 간 상호 동작
Fig. 4 Interaction during Multilateral Machine Learning

통과 필터에서는 이전의 값들과의 연산을 통해 RSSI를 보정한다. 보정된 RSSI는 파라미터 학습을 통해 얻은 거리 계산식(4)으로 계산되어 1차 거리를 계산한다. 1차 거리는 역전파 신경망(5)에 입력되어 최종적으로 추정된 거리를 반환한다. 거리 데이터는 제어모듈로 전달되어 스마트이동객체는 비콘과 떨어진 거리를 추정할 수 있다.

4. 구현 및 실험

4.1 실험 기기

데이터 수집을 위한 장비로는 Raspberry Pi 3 Model B+ 2대가 이용되었다. 표 4는 Raspberry Pi의 사양과 비콘의 설정 값을 나타낸다.

Raspberry Pi는 영국의 Raspberry Pi 재단에서 교육용으로 개발한 작고 저렴한 보드이다. 크기와 가격 대비 우수한 성능을 가지며 근거리 무선 통신 산업표준인 블루투스가 탑재되어 있어 사물인터넷 환경 구축에 용이하다. 운영체제는 Raspberry Pi 전용으로 개발된 리눅스 기반의 Raspbian을 이용하였다. 실험에서는 스마트 이동 객체를 SMO 2.4를 기반으로 설정하였다. SMO 2.4는 기존의 초음파 센서와 카메라를 이용하여 선도-추종 방식으로 동작하는 SMO 1.0를 기반으로 업그레이드된 스마트 이동객체이다. SMO 2.4는 실내 자율주행을 위한 다양한 장치와 센서가 탑재되어 있다. 기존에 앞바퀴의 속도 차로 방향을 조절하던 방식을 바퀴의 축을 조정하여 방향을 조정하는 방식으로 변경하였다. 또한 엣지 카메라를 이용하여 객체인식을 할 수 있고, LiDAR를 이용하여 생성한 격자맵을 따라 운용할 수 있다. 본 실험의 학습데이터를 수집하는 단계에서는 자율주행을 위한 센서를 배치하지 않고 구동 부분만 구현하였다[11-13].

표 4 Raspberry Pi 3 B+ Model의 사양과 비콘 설정 값
Table 4 Specification of Raspberry Pi 3 B+ and Setting for BLE Beacon

Raspberry 3 B+ Model	
CPU	Broadcom BCM2837B0, Cortex-A53 (ARMv8) 64-bit SoC @ 1.4GHz
RAM	1GB LPDDR2 SDRAM
Bluetooth	Bluetooth 4.2 (BLE)
OS	Raspbian Stretch
Beacon Setting	
advertising Interval	100ms
TxPower	-59dBm

4.2 학습 데이터 수집 과정

학습 데이터를 수집하기 위해 유동인구가 없는 50m 길이의 복도에서 실험 환경을 구축하였다. 그림 5는 Raspberry Pi로 구현한 장치를 이용하여 데이터를 수집하는 과정을 나타낸다. Raspberry Pi 한 대는 다른 기기를 탐지하고 연결할 수 있는 기능을 정지시키고, 지속적으로 advertising 하도록 설정하여 비콘 기능을 하도록 배치하였다.

또 다른 Raspberry Pi를 이용하여 학습데이터를 수집하는 스마트이동객체에 탑재하였다. 데이터의 수집 지점은 비콘으로부터 1m, 2m, 3m 그리고 4m 지점이다.

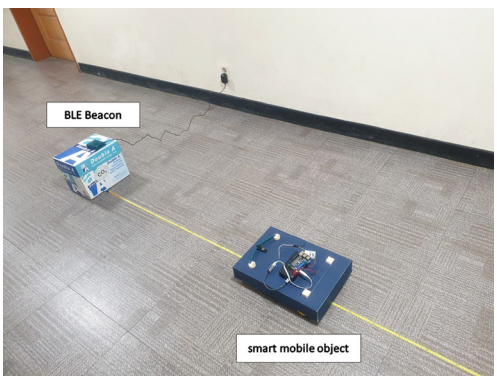

그림 5 실험 환경
Fig. 5 Experiment Environments

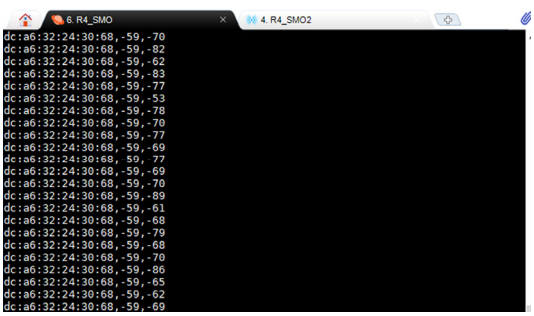

그림 6 스마트 이동객체에서 데이터를 수집하는 화면
Fig. 6 The Screen on SMO Collecting Data

그림 6은 실제 스마트 이동객체에서 데이터를 수집하는 과정을 보여주는 화면이다. 비콘 데이터 패킷은 수신할 때 필요한 부분만 가져오도록 처리하였다. 비콘을 식별할 수 있는 MAC address와 TxPower, RSSI 순으로 구성된다. 이 중 RSSI 데이터만 추출하여 저장한다. 위와 같은 과정을 통해 거리 별로 200개씩 총 800개의 데이터를 수집하였다. 이 중 75%를 학습에 이용하였고, 25%를 평가에 이용하였다.

5. 성능 평가

다측면 기계학습을 통해 얼마나 정확하게 거리를 측정할 수 있는지 검증하기 위해 각 단계별로 실측 거리 및 기존의 방식에 비해 정확도가 상승했는지 비교했다.

평가 1) 저주파 통과 필터의 데이터 보정률 평가

평가 2) 파라미터 학습으로 얻은 수식의 정확도 평가

평가 3) 역전파 학습을 마친 모델의 정확도 평가

평가 1)에서는 저주파 통과 필터의 성능 검증이다. 특정 거리에서 저주파 통과 필터를 적용한 데이터와 적용하지 않은 데이터가 그래프 상에서 분포하는 양상을 비교한다. 평가 2)에서는 파라미터 학습을 통해 얻은 거리 계산식을 이용하여, 실측 거리와 기존의 방식으로 측정되던 거리를 비교하여 오차율을 계산하고 성능향상 폭을 측정한다. 마지막 평가에서는 거리 계산식으로 계산한 거리를 학습된 역전파 신경망에 입력하여 평가 2)와 같은 방식으로 최종 거리측정 정확도를 평가한다.

5.1 저주파 통과 필터

저주파 통과 필터의 성능 비교를 위해서 비콘에서 1m 떨어진 지점에서 측정한 데이터로 필터처리를 하였다. 그림 7은 저주파 통과 필터를 사용하였을 때와 사용하지 않았을 때의 데이터 분포를 비교한 그래프이다. 그래프의 x축은 측정된 데이터의 수를 의미하고, y축은 RSSI 데이터의 세기를 나타낸다. 필터를 적용하기 이전에는 RSSI 데이터가 -47dBm ~ -33dBm 사이에 분포하지만, 필터를 적용한 이후에는 -43dBm ~ 39dBm에 분포한다. 저주파 통과 필터 전후로 71.5% 만큼 데이터 분포 폭이 감소하였다.

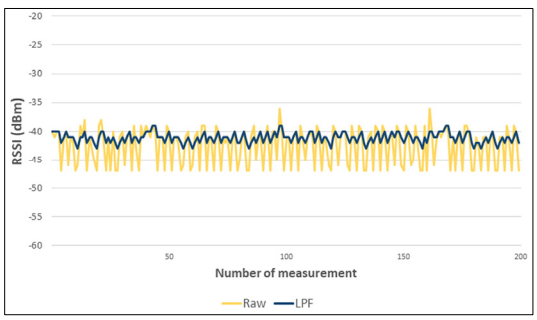

그림 7 저주파 통과 필터 성능 비교

Fig. 7 Low Pass Filter Performance Comparison

5.2 파라미터 학습

파라미터 학습을 통해 얻은 거리 계산식의 성능을 평가하기 위해 식 (2)를 통해 계산된 거리와 실제 거리와 비교했다. 식 (2)에서 요구되는 $TxPower$는 -59, 상수 n은 2로 설정하여 계산하였다.

그림 8-11에서 y축은 거리 값을 의미하고 x축은 입력한 데이터의 수를 의미한다. 데이터는 거리 별로 50개씩 총 200개이다. 그래프의 항목은 기존의 방식으로 계산된 거리, 파라미터 학습을 통해 얻은 수식으로 얻은 거리 그리고 데이터를 수집한 실제거리다. 각 지점의 오차율을 비교했을 때 1m 지점에서 기존의 방식은 87.06%의 평균 오차율을 보인다. 그리고 파라미터 학습에서 평균 13.69%의 오차율을 보이며 오차율이 상당히 개선된 것을 확인할 수 있다. 각 지점별 오차율은 2m 지점에서는

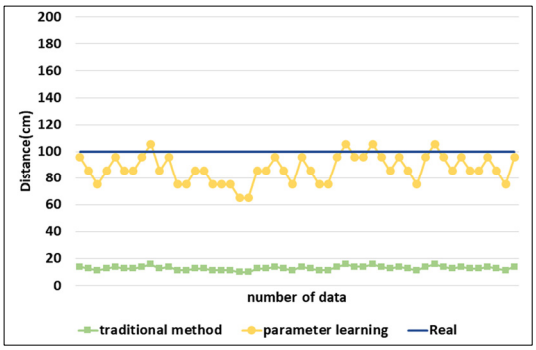

그림 8 1m 지점의 데이터에 기반을 둔 파라미터 학습 성능비교

Fig. 8 Parameter Learning Performance Comparison based on RSSI at 1m

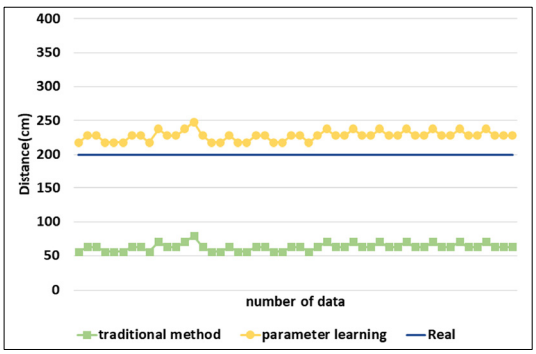

그림 9 2m 지점의 데이터에 기반을 둔 파라미터 학습 성능비교

Fig. 9 Parameter Learning Performance Comparison based on RSSI at 2m

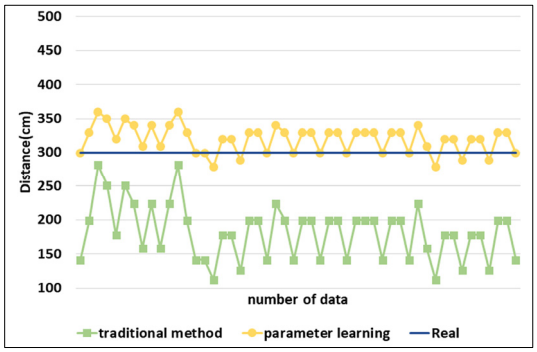

그림 10 3m 지점의 데이터에 기반을 둔 파라미터 학습 성능비교

Fig. 10 Parameter Learning Performance Comparison based on RSSI at 3m

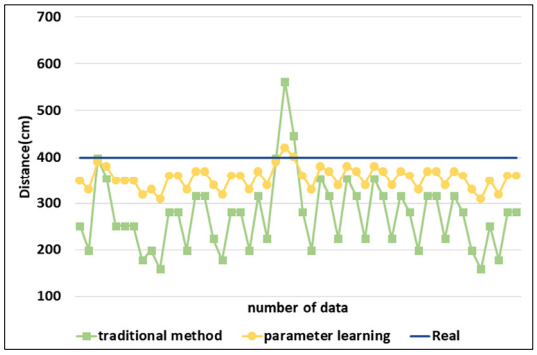

그림 11 4m 지점의 데이터에 기반을 둔 파라미터 학습 성능비교

Fig. 11 Parameter Learning Performance Comparison based on RSSI at 4m

68.42%에서 13.85%, 3m 지점에서 39.25%에서 7.62%로 개선되었다. 마지막으로 4m에서는 33.24%에서 11.49%로 오차율이 개선되었다. 하지만 오차율은 성능평가에 유효한 지표이지만, 이동객체의 거리 계산의 정확도 분석에는 측정 오차범위 안에 속하는 것이 필요하다 판단하였다. 본 논문에서는 정확한 거리 측정의 범위를 오차율 ±10% 설정하였다. 1m 지점에서 기존의 방식으로 계산된 거리는 유효한 오차 범위에 분포하는 값이 0%이다. 파라미터 학습의 경우 20%의 해당하는 값들이 유효 오차범위에 속한다. 각 거리 별로 비교해 봤을 때, 2m에서 0% 와 24%, 3m에서 4%와 82% 그리고 4m에서 4% 와 54%의 정확도 차이를 보인다. 결과적으로 기존 방식은 2%의 낮은 정확도를 나타내지만, 파라미터 학습의 정확도는 50%의 정확도를 보인다.

5.3 역전파 학습

구축한 신경망 모델을 기반으로 하여 역전파 학습을 진행하였다. 학습데이터를 파라미터 학습을 통해 획득한 거리 계산식으로 거리를 계산하고 정규화 했다. Input layer의 x는 거리 계산식으로 계산된 1차 측정 거리에 대응되며 Output layer의 y노드는 최종 측정된 거리를 출력한다. 본 단계에서는 역전파 신경망을 통과한 거리와 1차 측정 거리를 비교하여 정확도를 평가한다.

그림 12-15에서 y축은 거리 값을 의미하고 x축은 입력한 데이터의 수를 의미한다. 성능 평가를 위한 데이터는 파라미터 학습 성능평가를 위한 데이터와 동일하다. 그래프의 항목은 1차 추정 거리, 최종 추정 거리 그리고 실제 거리로 나눌 수 있다. 그림 12는 1m 지점의 성능평가를 위한 그래프이다. 1m 지점에서 파라미터 학습의 평균 오차율은 기존의 방식 보다 개선된 13.69%였지만, 역

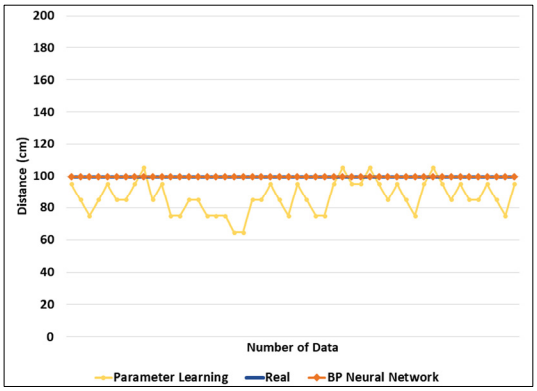

그림 12 1m 지점의 데이터에 기반을 둔 역전파 신경망의 성능평가

Fig. 12 Back Propagation Neural Network Performance Evaluation based on RSSI at 1m

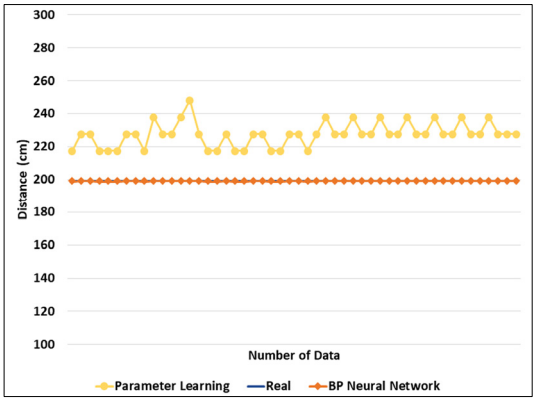

그림 13 2m 지점의 데이터에 기반을 둔 역전파 신경망의 성능평가

Fig. 13 Back Propagation Neural Network Performance Evaluation based on RSSI at 2m

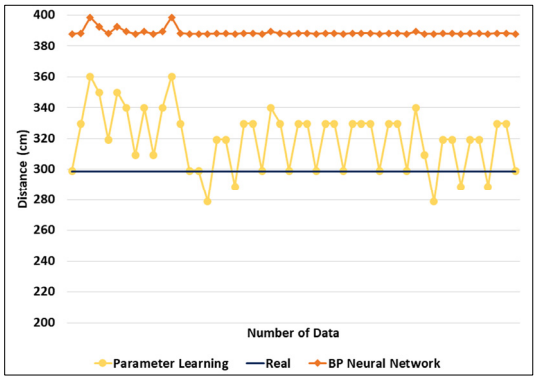

그림 14 3m 지점의 데이터에 기반을 둔 역전파 신경망의 성능평가

Fig. 14 Back Propagation Neural Network Performance Evaluation based on RSSI at 3m

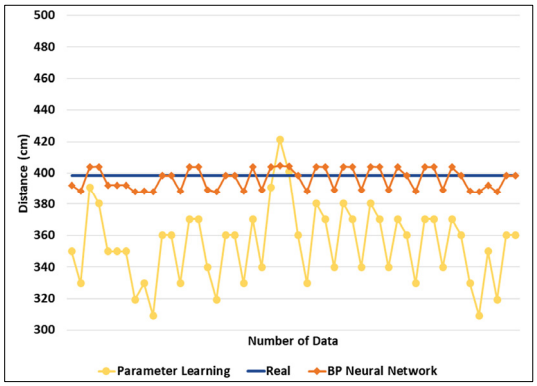

그림 15 4m 지점의 데이터에 기반을 둔 역전파 신경망의 성능평가

Fig. 15 Back Propagation Neural Network Performance Evaluation based on RSSI at 4m

전파 학습 이후에는 0.04%로 감소하여 상당히 정확도가 상승했다. 5.2에서 설정한 유효 오차 범위에 속한 데이터의 비율은 100%이다. 2m에서는 평균 오차율이 0.02%, 유효 오차 범위에 속하는 데이터의 비율은 100%이다. 4m에서는 평균 오차율이 1.57%이고 유효 오차 범위에 속하는 데이터의 비율은 100%이다. 그림 14는 3m 지점의 역전파 학습의 결과는 평균 오차율이 30%이고 유효 오차 범위에 속하는 데이터의 비율이 100%이다. 역전파 학습 단계에서 4m 데이터의 분포 영역과 중복되어 학습이 잘 이루어지지 않은 것으로 확인할 수 있다.

다측면 기계학습의 성능 평가를 종합하면 다음과 같다. 기존의 학습 방법은 평균 오차율이 56.99%이고 유효 오차범위에 속하는 데이터의 비율이 2%이다. 파라미터 학습을 수행한 후 성능 평가를 하였을 때, 평균 오차율이 11.66%로 감소하였고 유효 오차범위에 속하는 데이터의 비율이 50%로 증가하였다. 마지막으로 역전파 학습을 수행한 후 성능 평가를 하였을 때, 평균 오차율이 7.9%이고 유효 오차 범위에 속하는 데이터의 비율은 75%로 증가하였다. 성능 평가 척도인 유효 오차 범위 내 데이터의 비율을 가지고 비교할 경우 파라미터 학습을 진행한 후 기존 방식에 대비하여 성능이 2500%정도 증가하였고, 역전파 학습을 진행한 후 50%정도의 성능 향상이 있었다.

6. 결론 및 향후 계획

사물인터넷 환경에서 탐지 및 인식 기술은 자율 이동 객체의 5가지 핵심 기술 중에 하나이다. 실외 환경에서는 GPS를 이용한 위치 인식이 용이하지만, 실내의 경우는 GPS를 적용하기 어렵다. 실내 위치 인식을 위해 사용되는 기법 중 RSSI를 이용하여 거리를 계산하는 방식이 있다. 하지만 RSSI는 주변 환경에 의해 반사와 회절이 발생하여 변동폭이 크고 부정확하다는 단점이 있다. 본 논문에서는 RSSI 데이터를 이용하여 정확한 거리 측정을 위해 다측면 기계학습을 이용한 위치 보정 기법을 제안했다. 다측면 기계학습은 저주파 통과 필터, 파라미터 학습 그리고 역전파 학습을 순서대로 진행하는 기법이다. 저주파 통과 필터는 RSSI의 변화폭을 줄이는 역할을 한다. 저주파 통과 필터로 필터링한 데이터를 기반으로 하여 파라미터 학습을 진행한다. 파라미터 학습은 주어진 데이터를 바탕으로 최소제곱법을 수행하여 선형방정식을 얻는다. 그 후, RSSI를 거리로 변환할 수 있는 선형의 거리 계산식을 바탕으로 1차 추정 거리를 계산한다. 마지막으로 1차 추정 거리와 실제 거리의 오차를 줄이기 위해 역전파 학습을 진행한다. 실험을 위해 Raspberry Pi 3 B+ Model을 기반으로 BLE 비콘과 스마트 이동객체인 SMO 2.4를 구현하였다. 학습 데이터는 비콘에서 SMO를 이동시키면서 총 4개 지점에서 800개의 데이터를 수집하였고, 데이터의 75%는 학습에 이용하였고 25%는 성능평가에 이용되었다. 다측면 기계학습의 성능 평가는 각 단계별로 이루어졌다. 저주파 통과필터는 필터링 전후의 데이터 분포를 비교하였다. 그 결과 특정 지점에서 데이터의 상한과 하한의 차이가 71.5% 감소하였다. 파라미터 학습은 필터링된 RSSI를 기반으로 기존의 방식과 파라미터 학습의 정확도를 비교하였다. 기존 학습대비 유효 오차 범위에 속하는 데이터의 비중이 2500%로 증가하였다. 역전파 학습은 파라미터 학습 대비 유효 오차 범위에 속하는 데이터의 비중을 비교하였으며 기존의 50%의 비율이 75%로 증가하여 50%의 성능향상이 있었다.

본 연구를 통한 다측면 기계학습의 결과, 비콘과 가까

운 1m와 2m의 거리는 구분할 수 있었으나 3m가 넘어가는 지점에서는 명확하게 거리를 판단할 수 없었다는 한계점이 있었다. 그러나 실내에서 스마트 모바일 객체들 사이에서 반경 3m는 위치기반 서비스 프로그램을 사용하기에 알맞은 거리이다. 본 연구에서는 고정된 위치에 SMO를 배치하여 비콘과의 거리를 측정하고 정확도를 평가하였다. 향후 연구를 통해 SMO를 이동하면서 실제 이동 경로와 추정한 이동 경로를 비교하여 다측면 기계학습 알고리즘을 보완하고자 한다.

References

[1] H. Lee, M. Kim, and H. Bang, "IoT(Internet of Things) Technology Trend and Development Direction," *Korea Information Processing society review*, Vol. 21, No. 2, pp. 14-21, 2014.

[2] W. Kang, Y. Jung, I. Hwang, "Major technology of autonomous driving," *KICS Information & Communication Magazine - Open Lecture Series*, Vol. 35, No. 1, pp. 28-35, 2018.

[3] J. Kim, T. Ahn, S. Kim, C. Ahn, "Indoor Zone Recognition System using RSSI of BLE Beacon," *Journal of the Korean Society for Railway*, Vol. 19, No. 5, pp. 588-591, 2016.

[4] H. Hoshi, H. Ishuzuka, A. Kobayashi, A. Minamikawa, "An Indoor Location Estimation using BLE Beacons Considering Movable Obstructions," *2017 Tenth International Conference on Mobile Computing and Ubiquitous Network*, pp. 58-59, 2017.

[5] C. Lee, Y. Han, S. Jeon, D. Seo, I. Jung, "Smart Parking System Using Ultrasonic Sensor and Bluetooth Communication in Internet of Things," *KIISE Transactions on Computing Practices*, Vol. 22, No. 6, pp. 268-277, 2016.

[6] Y. Wang, X. Yang, Y. Zhao, Y. Liu, L. Cuthbert, "Bluetooth Positioning using RSSI and Triangulation Methods," *IEEE 10th Consumer Communications and Networking Conference*, pp. 837-842, 2013.

[7] S. Kim, "Essential Kalman Filter," pp. 25-29, A-JIN, 2010.

[8] T. Odaka, "Machine Learning to Learn While Making," pp. 180, Hanbit Media, Inc., 2015.

[9] W. Kim, M. Kim, I. Jung, "A Smart Sensing Period Control on Back Propagation Neutral Network in IoT," *KIISE Transactions on Computing Practices*, Vol. 25, No. 8, pp. 377-388, 2019.

[10] R J. Erb, "Introduction to Backpropagation Neural Network Computation," *Pharmaceutical Research*, Vol. 10, No. 2, pp. 165-170, 1993.

[11] D. Lim, Y. Kim, C. Jeon, S. Jeon, D. Seo, I. Jung, "Leader-Follower based Smart Mobile Objects in Internet of Things," *2019 IEEE International Conference on Consumer Electronics (ICCE)*, 2019.

[12] Y. Kwon, I. Choi, H. Jang, G. Lee, H. Lim. I, I. Jung, "Location Tracking of Smart Mobile Object on Beacon RSSI," *KIISE and KBS Joint Symposium*, Vol. 13, No. 1, pp. 47-49.

[13] H. Jang, G. Lee, I. Choi, W. Kim, D. Lim, I. Jung, "Smart Steering System for Indoor Autonomous Mobile Object," *KIISE and KBS Joint Symposium*, Vol. 13, No. 1, pp. 53-55.

권 용 훈

2019년 강원대학교 원예학과 졸업(학사)
2019년~현재 강원대학교 컴퓨터정보통신공학과 석사과정. 관심분야는 사물인터넷, 자율주행, 스마트팜

정 인 범

정보과학회 컴퓨팅의 실제 논문지 제 26 권 제 5 호 참조